

同濟大學

科研前沿与实践（下）开题报告

课题名称 基于医患对话的智能病历生成系统

副 标 题 _____

学 院 国豪书院

专 业 软件工程

学生姓名 黎高和 学 号 2351097

2026 年 4 月 8 日

基于医患对话的智能病历生成系统

Intelligent Medical Record Generation System Based on Doctor-Patient Dialogue

1 研究背景

门诊问诊的场景中，医生需要在短时间内，同时完成询问病人情况、做判断、还有写病历三项任务。将医患对话的语音自动转录并生成结构化病历，理论上可减少临床文书工作量。可其真正困难的地方，并不是把对话“写出来”，而是怎么把口语的、有噪音的、不按照标准说法的对话，稳定地转成正确的、可用的医学专业词。已有研究说明，从医患对话中生成临床记录是可行的^{[1][2]}。但在医疗的情况下，对于事实的一致性、关键遗漏、以及医学专业术语的准确度，这些要求都比一般做摘要的任务要高出很多。特别是在中文的门诊情况中，病人常用口语描述症状，医生的口头说明中，又有许多低频的专科词、药品名与检查名，造成自动语音识别（ASR）还有大模型生成时，常会出现术语错误和幻觉的情况。

中文医疗对话信息抽取和结构化病历生成已有研究基础。MIE 把医生病人之间的多轮对话里面的症状、检查、手术还有它们的状态抽取出来，这表明“从对话到病历”可当作一个独立的模块来建模^[3]。后来的 SAFE 更进一步地指出，说话的人是谁、跨轮次的互动，对抽取准确率有重要影响^[4]。比较近期的 EMRModel 也说明大模型加上轻量的微调跟格式的限制，已经能够把中文的医疗咨询对话转成有结构的病历^[5]。但是，这些研究的大部分的重点在抽取和生成本身，对于医学专业词的纠错以及事实上的约束的讨论相对不足。

本课题拟围绕“医学术语纠错与降幻觉”这一核心问题，设计一个面对中文一般门诊录音的 AI 问诊的助手。系统以录音为输入，经过医疗 ASR、术语纠错与标准化、结构化病历生成三个环节，最终输出标准化病历。研究重点不在于单纯追求生成的流畅，更在于提高医学术语的正确率、标准化程度和病历内容的事实可靠性。

2 国内外研究现状

2.1 端到端病历生成

SOAP note (Subjective-Objective-Assessment-Plan, 主诉-客观检查-评估-计划) 是国际上临床病历的标准格式，按此格式拆分的模块化摘要比纯抽象式生成更稳健，在长对话和 ASR 噪声下具有优势^[1]。MTS-Dialog 和 MEDIQA-Chat 这一些数据集的提出，让临床记录的生成可以有系统性的评测，也使得“关键信息的遗漏”还有“事实的一致性”变成了评断的核心面向^[2]。从这些研究里面可以知道，病历的生成并不只是简单的摘要任务，而是具有强结构和强事实约束的一种临床文字生成任务。

中文场景下，像是 MIE、SAFE 这些工作，它们主要的重心是放在医疗对话的信息抽取上^{[3][4]}。其先抽取病历中的证据，再组织为结构化输出，保证病历证据的可追溯性。另外一方面，EMRModel 则展示出另一条路线：使用 LoRA 的微调方法以及系统提示词把对话直接映射到结构化的病历模板中。这说明“带有格式约束的大模型生成”在中文结构化病历的任务上，已经具备较强的可行性^[5]。

2.2 医疗 ASR 与术语纠错

准确识别医疗录音中的低频术语，是系统成功的前提。ASR-EC Benchmark 证明，仅靠提示词让大模型做中文 ASR 纠错容易出现过度纠正^[6]。这意味着本课题不能把术语纠错完全视为纯文本后处理，而应至少保留 n best 假设与置信度信息。

专科词识别方面，有研究提出了 post decoder biasing 的做法。其利用偏置词表来增强稀有医学词语识别，对于低频词语的错误率有明显改善^[7]。针对中文的实体纠错问题，DiCODER 透过词典的检索、拼音相似度的计算，还有受控解码的方式，减少了对低频实体的错误修改与幻觉实体的产生^[8]。

这一类工作提示：医学术语的纠错，不应该只去依赖大模型自发地去“猜测”。更加可行的方案是让词典的比对、发音的相似性、候选词语的限制这些机制显式进入解码的过程。

2.3 医学术语标准化与降幻觉

医学术语纠错的终点不应只是把错字改对，更应把转写结果映射为标准术语。MCSCSet 证明医学领域拼写纠错与开放领域差异很大，通用中文纠错模型迁移到医学场景会显著退化，因此必须依赖领域数据和领域混淆集^[9]。在标准化层面，中文诊断和操作术语映射到 ICD 的研究表明，同义词知识库与 recall rank 框架能显著提升规范化效果^[10]。RRNorm 进一步指出，中文诊断表述中常有缩写、并列和多义压缩，必须先把复杂表述拆成更原子的术语成分，再做召回与排序^[11]。这与门诊口语高度一致，因为患者口语和医生缩略表达本身就常是非标准的。

在降低幻觉现象的这一方面，Re3Writer 所提出来的 retrieve reason refine 的框架透过检索相似的病例和引入医学知识的限制，帮助提升临床文本生成的召回率和精确率^[12]。MEDEC 则把医疗错误的检测还有纠错单独做成一个评测的基准，并说明了“首先识别错误，进而予以纠正”的评测方式更能看出系统是否具备临床上的可靠性^[13]。

以上工作表明，医疗文本的生成如果要从“可写”进步到“可信”的阶段，就必须要把检索的机制、标准化的词表和错误的检测都纳入到系统设计。

2.4 现有研究的不足

现有工作虽覆盖了病历生成、信息抽取、ASR 纠错、术语标准化和事实评测等多个环节，但仍存在三点不足。

- 中文门诊录音到标准病历的完整系统研究相对分散，模块之间常分别优化，缺少围绕术语准确性的统一设计
- 许多病历生成研究重点在文本相似度和整体摘要质量，对专科术语误识别和非标准表达规范化关注不足
- 降幻觉研究多面向英文临床文本生成，直接针对中文门诊口语与录音转写误差的证据约束机制仍不充分

因此，本课题具有明确的工程价值与研究空间。

3 研究目标与核心问题

本课题拟构建一个面向中文通用门诊问诊录音的 AI 问诊助手，完成以下目标。

- 将医患录音自动转写为带说话人信息的对话文本
- 从对话中抽取主诉、现病史、既往史、检查建议、用药信息等病历要素
- 将口语化和误转写的医学表达纠正并规范化为标准医学术语

- 生成结构化病历，并对关键术语给出检索校验与证据约束
- 建立覆盖识别、规范化、生成和临床安全的实验评测体系

围绕上述目标，课题聚焦以下核心问题。

1. 如何在门诊录音噪声、多说话人交互和低频医学词条件下，提高关键术语的识别率
2. 如何将 ASR 输出中的错词、同音词和非标准口语表达映射到标准医学术语
3. 如何在结构化病历生成过程中抑制幻觉，并减少关键医疗事实遗漏
4. 如何设计既适合工程实现又能反映临床可用性的实验方案与评价指标

4 研究内容与技术路线

4.1 总体思路

系统采用三阶段流水线，并在第二阶段与第三阶段之间加入术语校验闭环。

模块	输入	输出	关键方法
医疗 ASR	门诊录音	带说话人标签的转写文本	医疗词表偏置、置信度、n best 候选
术语纠错与标准化	ASR 文本与候选词	标准化医学术语序列	词典检索、拼音匹配、候选约束、实体链接
结构化病历生成	纠错后对话与病历模板	结构化病历	大模型抽取生成、章节约束、检索校验
错误检测与回写	初版病历与证据库	修正后病历与证据说明	错误检测、候选比对、事实校验

4.2 模块一：医疗 ASR 与关键术语保留

自动语音识别模块的设计并不是单纯地去追求整段文字的最低字错误率，参考文献^[7]的做法，其会专门为门诊的医学内容构建一个偏置词表。将疾病、症状、检查、药物还有手术的名字当作是高优先级的候选词来处理。另外参考文献^[8]的做法，其保留多个候选的假设，为后续术语纠错提供选择。

具体来说，这一个 ASR 模块的重点，主要是要输出下面这三种类别的信息。

- 一次转写结果
- 关键片段的 n best 候选

- 词级置信度与说话人标签

4.3 模块二：医学术语纠错与标准化

这是本课题的主创新模块，旨在实现“候选受限的证据化修正”。整体采用“检测可疑术语→召回受控纠错→标准化映射”的四步流程。

该流程首先从识别文本中的可疑术语片段入手，此处借鉴了医学拼写纠错的思路，因为 MCSCSet 等研究指出医学领域需要专门的混淆集与领域模型^[9]。在此基础上，参考 DiCODER 与知识提示方法，可从预构建的词典中召回相关候选词，并综合字形、拼音及上下文语义相似度来构建候选集^{[8][14]}。纠错生成则采用受控解码策略，将模型的修改操作严格限制在候选集与通用字表构成的范围内，以此规避模型凭空生成新术语的风险^[8]。最后，将纠正后的术语映射至标准词表或编码体系。映射过程可参考实体链接中的 recall-rank 框架^[10]，并结合 RRNorm 的术语成分解析思想，即把复杂的并列表述拆分为原子术语后再进行规范化映射^[11]。

4.4 模块三：结构化病历生成与检索约束

结构化病历生成不直接从原始 ASR 文本端到端生成，而是在纠错后的术语序列和病历模板约束下进行。信息抽取层可借鉴 MIE 和 SAFE，将病历要素视为实体加状态抽取任务，从对话中识别症状、检查、治疗建议及其肯定、否定、建议等状态^{[3][4]}。生成层则参考 EMRModel，用代码风格模板或 JSON 模板约束输出字段，减少格式漂移^[5]。

在病历生成之后，为降低幻觉，系统拟加入一个检索校验的步骤。参考 Re3Writer 所提出的想法，系统会从术语词库、标准病历模板、相似的历史样本中检索能提供支持的证据，并要求每个关键的字段所填写的内容，都必须在输入的对话或知识库能找到相对应的依据^[12]。如果生成的疾病名、药品名或是检查名无法被检索，那么系统会触发错误检测，并进行回写的修正动作。

4.5 拟解决的关键技术问题

问题	形成原因	拟采用方法
低频医学词识别错误	通用 ASR 词频不足，门诊语音噪声大	医疗加权词表，多候选保留 ^{[6][7]}
同音错词与口语化误写	中文医学术语同音近音多，患者表达非标准	拼音相似召回，医学混淆集，受控纠错 ^{[8][9]}
复杂诊断短语难规范化	缩写、并列、复合表达压缩多个含义	成分拆解为简单术语再重构 ^{[10][11]}
结构化病历幻觉	生成模型脱离证据自由发挥	模板约束，检索增强，错误检测后回写 ^{[12][13]}

5 创新点

1. 围绕“术语纠错与降幻觉”构建系统主线，而不是把它作为附属后处理。与仅关注病历生成质量的方案相比，本课题把术语准确性设为中心目标。
2. 提出面向中文门诊录音的受限候选医学术语纠错机制。该机制联合使用音频候选、拼音相似、医学词典和上下文语义，避免大模型自由改写导致的过度纠正与幻觉实体。
3. 将术语纠错与术语标准化统一到同一闭环中。系统不仅修正错词，还将非标准表达映射为标准病历术语或标准编码，提升输出的临床规范性^{[10][11]}。
4. 在结构化病历生成后加入检索校验和错误回写机制，使关键字段具备可追溯证据，从而降低无依据生成和关键事实遗漏^{[12][13]}。

6 实验设计

6.1 数据集与数据构建

本课题拟采用“公开数据集验证方法→可控构造中文实验集验证系统”的思路。

如果难以获得真实中文门诊录音，可先构建小规模原型数据集。方法是选取标准中文病历模板，邀请标注者依据病历内容逆向编写问诊对话，再通过语音合成得到录音，最后注入可控 ASR 错误。这一路线与 MTS-Dialog 的逆向数据构建思路一致^[2]。

6.2 对比基线

实验至少设置以下基线。

- 原始 ASR 加通用大模型纠错后病历生成
- ASR 加术语词典纠错后病历生成
- ASR 加本课题受控术语纠错与标准化后病历生成

6.3 评价指标

评价分为四层。

层次	指标	评估对象	说明
识别层	字符错误率，关键词召回率，低频词错误率	ASR 转写的单个字/词	评估 ASR 转写的单个字/词识别错误 ^{[6][7]}

术语层	纠错精确率/召回率/F1、Topk 和标准化的准确率	医学术语	评估医学专业术语的错词发现与标准化映射 ^{[9][10]}
病历层	章节完整率	结构化字段	评估结构化病历各字段的生成完整度 ^[5]
安全层	事实精确率、事实召回率、遗漏率、幻觉率	整个病历的陈述	评估生成病历与原始问诊记录的事实一致性 ^{[2][16]}

其中，病历生成不能只看 ROUGE 这类衡量文本相似度的指标。已有研究表明，自动指标与人工判断并不总是一致的^[15]。因此，本课题拟采用“自动指标加人工审核”的组合进行评价。

6.4 人工评测方案

人工评测重点关注以下维度^{[15][2]}。

- 术语是否正确
- 是否存在关键遗漏
- 是否出现凭空生成的诊断、药物或检查
- 病历字段是否完整
- 医生后编辑工作量是否下降

可采用三名具有医学背景的评审者，对同一批样本进行双盲评分，并记录错误类型。错误标签可分为术语错误、事实矛盾、关键遗漏、格式错误和冗余表达。

7 技术可行性分析

从已有研究看，本课题具备较强可行性。

中文医疗对话抽取与结构化病历生成已经存在可复用方法基础^{[3][4][5]}。中文 ASR 纠错、医疗拼写纠错和术语标准化都有公开任务设定与基线^{[6][9][10]}。其次，检索增强和错误检测的研究已为降幻觉提供成熟思路^{[12][13]}。因此，本课题可以不需要从零发明所有模块，而是可以在成熟模块上做面向中文门诊场景的系统整合与重点创新。

参考已有研究，在工程实现角度上，本课题可优先使用通用的中文大模型，再配合上模板的限制，用较低的成本来搭建一个原型的系统^[5]。至于术语纠错的模块，可优先加入词典的检索与重排序，逐步再加入受控生成、回写的校验机制。技术路线较为清晰，阶段性成果较为明确。

8 预期成果

- 一个面向中文门诊问诊录音的 AI 问诊助手原型系统

- 一套医学术语纠错与标准化方法
- 一种带检索约束的结构化病历生成流程

9 进度安排

阶段	时间	主要内容
第一阶段	第 1 月	阅读文献，明确病历模板与术语词表，搭建基础 ASR
第二阶段	第 2 月	实现术语纠错与标准化模块，完成小规模数据构建
第三阶段	第 2 月	接入大模型生成结构化病历，加入检索校验与错误回写
第四阶段	第 3 月	完成对比实验和人工评测
第五阶段	第 3 月	整理结果，撰写论文与系统说明

参考文献

- [1] K. Krishna, S. Khosla, J. P. Bigham, and Z. C. Lipton, “Generating SOAP Notes from Doctor-Patient Conversations Using Modular Summarization Techniques,” Annual Meeting of the Association for Computational Linguistics, pp. 4958-4972, May 2020, doi: 10.18653/v1/2021.acl-long.384.
- [2] A. B. Abacha, W. Yim, Y. Fan, and T. Lin, “An Empirical Study of Clinical Note Generation from Doctor-Patient Encounters,” Conference of the European Chapter of the Association for Computational Linguistics, pp. 2283-2294, 2023, doi: 10.18653/v1/2023.eacl-main.168.
- [3] Y. Zhang et al., “MIE: A Medical Information Extractor towards Medical Dialogues,” Annual Meeting of the Association for Computational Linguistics, pp. 6460-6469, Jul. 2020, doi: 10.18653/v1/2020.acl-main.576.
- [4] Y. Xia et al., “A Speaker-Aware Co-Attention Framework for Medical Dialogue Information Extraction,” Conference on Empirical Methods in Natural Language Processing, pp. 4777-4786, 2022, doi: 10.18653/v1/2022.emnlp-main.315.
- [5] S. Zhao et al., “EMRModel: A Large Language Model for Extracting Medical Consultation Dialogues into Structured Medical Records,” ArXiv, vol. abs/2504.16448, Apr. 2025, doi: 10.48550/arXiv.2504.16448.
- [6] V. J. Wei, W. Wang, D. Jiang, Y. Song, and L. Wang, “ASR-EC Benchmark: Evaluating Large Language Models on Chinese ASR Error Correction,” Conference on Empirical Methods in Natural Language Processing, pp. 1567-1575, Dec. 2024, doi: 10.48550/arXiv.2412.03075.
- [7] H. Liu, Y. Wang, and Y. Wang, “Post-decoder Biasing for End-to-End Speech Recognition of Multi-turn Medical Interview,” ArXiv, vol. abs/2403.00370, Mar. 2024, doi: 10.48550/arXiv.2403.00370.
- [8] R.-Z. Li and W. Peng, “Dictionary-driven Chinese ASR Entity Correction with Controllable Decoding,” 2023 Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC), pp. 1542-1548, Oct. 2023, doi: 10.1109/APSIPAASC58517.2023.10317469.
- [9] W. Jiang et al., MCSCSet: A Specialist-annotated Dataset for Medical-domain Chinese Spelling Correction, 2022, doi: 10.1145/3511808.3557636.
- [10] Q. Wang et al., “A study of entity-linking methods for normalizing Chinese diagnosis and procedure terms to ICD codes,” Journal of biomedical informatics, pp. 103418, Apr. 2020, doi: 10.1016/j.jbi.2020.103418.
- [11] Y. Fan, Y. Zhu, K. Xue, J. Liu, and T. Ruan, “RRNorm: A Novel Framework for Chinese Disease Diagnoses Normalization via LLM-Driven Terminology Component Recognition and Reconstruction,” Annual Meeting of the Association for Computational Linguistics, pp. 9162-9175, 2024, doi: 10.18653/v1/2024.findings-acl.544.
- [12] F. Liu et al., “Retrieval-Augmented and Knowledge-Grounded Language Models for Faithful Clinical Medicine,” Oct. 23, 2022.
- [13] A. B. Abacha et al., “MEDEC: A Benchmark for Medical Error Detection and Correction in Clinical Notes,” ArXiv, vol. abs/2412.19260, Dec. 2024, doi: 10.48550/arXiv.2412.19260.
- [14] M. Zhang et al., “Knowledge Prompt for Whisper: An ASR Entity Correction Approach with Knowledge Base,” 2023 IEEE International Conference on Big Data (BigData), pp. 2975-2979, Dec. 2023, doi: 10.1109/BigData59044.2023.10386366.
- [15] F. Moramarco et al., “Human Evaluation and Correlation with Automatic Metrics in Consultation Note Generation,” Annual Meeting of the Association for Computational Linguistics, pp. 5739-5754, Apr. 2022, doi: 10.48550/arXiv.2204.00447.
- [16] A. B. Abacha, W. Yim, G. Michalopoulos, and T. Lin, “An Investigation of Evaluation Metrics for Automated Medical Note Generation,” ArXiv, vol. abs/2305.17364, May 2023, doi: 10.48550/arXiv.2305.17364.