

中文门诊病历生成开发任务清单

Table of Contents

- 中文门诊病历生成开发任务清单
- 里程碑总览
- 第一部分 基础工程
 - T1 项目脚手架
 - T2 数据库与存储初始化
 - T3 病历 schema 固定
- 第二部分 音频与转写链路
 - T4 音频上传与任务创建
 - T5 funASR 接口封装
 - T5.5 ASR 后处理纠错
 - T6 转写结果标准化
- 第三部分 证据选择模块
 - T7 字段清单与触发词设计
 - T8 规则证据筛选器
 - T9 evidence 打分器
- 第四部分 术语纠错与规范化
 - T10 术语词表收集
 - T11 候选召回模块
 - T12 候选排序模块
 - T13 可疑术语标记
- 第五部分 病历要素抽取
 - T14 基础字段规则抽取
 - T15 症状与检查抽取
 - T16 诊断与建议抽取
 - T17 抽取结果聚合
- 第六部分 病历生成模块

- T18 槽位填充器
 - T19 主诉生成器
 - T20 现病史生成器
 - T21 病历版本化
- 第七部分 验证与审核
 - T22 规则校验器
 - T23 风险标记器
 - T24 审核页面
 - T25 审核日志
- 第八部分 评测与样例集
 - T26 构建小测试集
 - T27 指标脚本
 - T28 错误分析表
 - T29 展示样例整理
- 推荐执行顺序
- 最小可交付版本
- 后续增强任务
- 最终建议
- References

中文门诊病历生成开发任务清单

这份清单服务于一期原型开发。目标不是追求最强模型，而是尽快跑通“录音到结构化病历草稿”的闭环，并保证关键字段可回链到原始证据。整体开发顺序遵循模块化流水线思路，因为这比端到端黑箱更适合中文门诊场景的调试和渐进迭代 [1], [2], [3], [4]。

里程碑总览

里程碑	目标	核心产出
M1	跑通音频到转写	音频上传、funASR 接口、ASR 纠错、turn 级转写
M2	跑通文本到病历	evidence 筛选、术语规范化、抽取、病历 JSON
M3	跑通审核闭环	规则校验、审核页面、版本保存
M4	跑通评测闭环	小测试集、指标脚本、错误分析表

第一部分 基础工程

T1 项目脚手架

- 建立后端项目结构
- 建立前端项目结构
- 配置开发环境和依赖管理
- 建立配置文件机制，区分 dev 和 prod
- 建立日志目录和数据目录

交付物：

- 可运行的前后端空项目
- README 启动说明
- 统一配置文件

验收标准：

- 新环境可在一小时内完成启动
- 后端 health check 可访问
- 前端首页可访问

T2 数据库与存储初始化

- 建 visits 表
- 建 transcript_turns 表
- 建 evidence_spans 表
- 建 normalized_terms 表
- 建 extracted_items 表

- 建 emr_records 表
- 建 audit_logs 表
- 建本地文件存储或 MinIO 存储目录

交付物：

- 数据库建表脚本
- ORM 模型
- 初始化脚本

验收标准：

- 能插入一次完整 visit 的全链路样例数据
- 关键表之间关联正确

T3 病历 schema 固定

- 固定一期病历 JSON schema
- 固定字段枚举值
- 固定 evidence 数据结构
- 固定 validation error 数据结构

交付物：

- schema 文档
- Pydantic 或 dataclass 定义
- 1 份标准样例 JSON

验收标准：

- 任意模块都能按同一 schema 读写
- 不再出现字段名频繁改动

第二部分 音频与转写链路

T4 音频上传与任务创建

- 支持上传 wav 和 mp3
- 生成 visit_id

- 保存原始音频路径
- 创建处理任务状态机

交付物：

- 上传接口
- 任务状态字段
- 上传页面原型

验收标准：

- 上传后数据库能看到 visit 记录
- 文件能落盘或进入对象存储

T5 funASR 接口封装

- 封装 funASR 调用
- 输出 turn 级文本
- 保留 start_ms 和 end_ms
- 保留 speaker 信息
- 保留 confidence 或可替代评分

交付物：

- asr service
- 原始转写 JSON 存储逻辑
- 一条样例推理脚本

验收标准：

- 任意测试音频都能返回结构化 turn 列表
- 转写结果可写入 transcript_turns 表

T5.5 ASR 后处理纠错

- 建立医疗领域常见 ASR 错误映射表
- 实现基于词表的纠错规则
- 实现基于拼音相似度的候选召回
- 保留原始文本和纠错后文本的双版本

- 标记纠错置信度

交付物：

- asr postprocessor 模块
- 医疗术语 ASR 错误映射表
- 纠错前后对比样例

验收标准：

- 常见医疗术语 ASR 错误能被纠正
- 纠错不引入新的错误
- 低置信度纠错被标记为需人工审核

这一阶段在转写标准化之前进行纠错，是因为 ASR 错误会直接影响后续的证据筛选和术语规范化。基于词表的规则纠错比大模型纠错更可控，避免过度纠正问题 [7]。

T6 转写结果标准化

- 统一标点和空白格式
- 统一 speaker 标签格式
- 统一时间戳格式
- 增加 turn_id 和顺序索引

交付物：

- transcript normalize 工具函数
- 标准化后的转写样例

验收标准：

- 不同来源转写结果可统一进入后续模块

第三部分 证据选择模块

T7 字段清单与触发词设计

- 确定一期字段列表
- 为主诉、现病史、既往史、检查、诊断、建议建立触发词表
- 标记更偏医生发言还是患者发言

交付物：

- 字段词表文件
- 字段到 speaker 偏好映射表

验收标准：

- 每个核心字段至少有一批可用触发词

T8 规则证据筛选器

- 基于触发词筛 turn
- 基于 speaker 过滤 turn
- 基于句长和 confidence 做简单过滤
- 为每个字段返回 top k 候选 evidence

交付物：

- evidence service 第一版
- 候选 evidence 输出 JSON

验收标准：

- 能明显过滤寒暄和无关内容
- 关键字段都有候选 evidence

T9 evidence 打分器

- 设计简单打分公式
- 综合关键词命中、词表相似度、speaker、confidence
- 对 evidence 排序

交付物：

- evidence scoring 模块
- 可视化样例输出

验收标准：

- top 1 到 top 3 候选基本可用

这一阶段对应“noteworthy utterance”先筛证据再做下游处理的思路 [5]。一期先做规则加打分，不急着训练复杂分类器。

第四部分 术语纠错与规范化

T10 术语词表收集

- 建症状词表
- 建检查词表
- 建药物词表
- 建诊断词表
- 为每个词条补同义表达和常见口语表达

交付物：

- 四类术语词表文件
- 词条标准名和别名映射

验收标准：

- 高频门诊术语有基本覆盖

T11 候选召回模块

- 实现字面匹配召回
- 实现编辑距离召回
- 实现拼音相似召回
- 实现同义词召回
- 输出 top k 候选

交付物：

- terminology recall 模块
- 候选术语样例集

验收标准：

- 常见错写或近音词能召回正确候选

T12 候选排序模块

- 设计排序特征
- 综合上下文、字段类型、候选分数

- 输出 top 1 规范化结果和 top k 候选

交付物：

- terminology rank 模块
- 规范化结果存储逻辑

验收标准：

- 结果中同时保留 source_text 和 normalized_text
- 常见术语能稳定归一到标准名

T13 可疑术语标记

- 根据低 confidence 标记风险词
- 根据词表外命中标记风险词
- 将高风险术语加入人工审核提示

交付物：

- terminology risk 标记逻辑

验收标准：

- 高风险术语会在前端明确提示

这一阶段优先采用 recall and rank，因为它更稳、更适合中文术语规范化第一版 [6]。不直接依赖通用大模型纠错，是为了避免过度纠正问题 [7]。

第五部分 病历要素抽取

T14 基础字段规则抽取

- 性别规则抽取
- 年龄规则抽取
- 日期和时长规则抽取
- 否定词识别

交付物：

- rule extraction 模块

验收标准：

- 基础字段可直接落槽

T15 症状与检查抽取

- 从规范化术语和 evidence 中抽取症状项
- 为症状打状态标签
- 抽取检查项目及其 done 或 suggested 状态

交付物：

- extracted_items 第一版

验收标准：

- 症状、检查字段能结构化输出
- 每个项都带 evidence_refs

T16 诊断与建议抽取

- 仅抽取医生明确表达的诊断
- 建 suggested 和 confirmed 区分
- 抽取用药、检查建议、复查建议

交付物：

- diagnosis 和 plan 抽取逻辑

验收标准：

- 不把怀疑句误写成确诊
- 不凭空生成建议

T17 抽取结果聚合

- 将 extracted_items 合并到统一结构
- 去重和冲突处理
- 为同一字段保留多条 evidence

交付物：

- extraction aggregator

验收标准：

- 同一字段不会出现明显重复和自相矛盾

这一阶段以抽取优先路线为主，因为这比直接自由生成更稳，也更符合中文医疗对话当前成熟做法 [3], [4], [8], [9]。

第六部分 病历生成模块

T18 槽位填充器

- 将 extracted_items 映射到 schema
- 填充 patient、chief complaint、history、examinations、assessment、plan
- 对缺失字段做统一留空策略

交付物：

- slot filling 模块
- 第一版 emr_json

验收标准：

- JSON 稳定合法
- 核心字段结构正确

T19 主诉生成器

- 用症状加时间模板生成主诉
- 控制字数和格式
- 保留 evidence

交付物：

- chief complaint generator

验收标准：

- 主诉简洁且与 evidence 一致

T20 现病史生成器

- 用症状、持续时间、伴随症状模板生成现病史摘要

- 控制只复述已抽取事实

交付物：

- history summary generator

验收标准：

- 现病史可读且不新增事实

T21 病历版本化

- 每次生成病历保留 version
- 区分 system draft 和 reviewed draft

交付物：

- version 字段和保存逻辑

验收标准：

- 能回看不同版本病历

第七部分 验证与审核

T22 规则校验器

- 检查必填字段
- 检查 evidence 是否存在
- 检查值域是否合法
- 检查诊断 certainty 是否缺失
- 检查基础冲突，如性别和文本明显冲突

交付物：

- validation service 第一版
- validation_errors 列表

验收标准：

- 明显结构错误都能被标出

T23 风险标记器

- 根据 ASR confidence 标记 asr_risk
- 根据高风险术语和缺证据字段标记 needs_human_review

交付物：

- quality_flags 生成逻辑

验收标准：

- 高风险样本不会被当成低风险输出

T24 审核页面

- 展示转写文本
- 展示病历字段
- 点击字段可查看 evidence
- 支持手工修改字段
- 支持保存审核版本

交付物：

- review ui 第一版

验收标准：

- 可以完成一次人工审核闭环

T25 审核日志

- 记录修改前后内容
- 记录修改人和时间
- 记录修改原因可选项

交付物：

- audit log 保存逻辑

验收标准：

- 可追踪每个字段的修改历史

这一阶段先做规则校验和人工审核，符合临床 note generation 中“先拦错，再谈自动修正”的现实路径 [10], [11], [12]。

第八部分 评测与样例集

T26 构建小测试集

- 收集 20 到 50 条样本
- 为每条样本准备人工转写
- 为每条样本准备参考病历 JSON
- 为核心字段标注 evidence

交付物：

- test set 第一版

验收标准：

- 每个核心字段都有覆盖样本

T27 指标脚本

- 转写层 CER 和关键词召回率
- 术语层规范化准确率和 top k 命中率
- 抽取层字段级 P R F1
- 病历层字段完整率

交付物：

- evaluation scripts
- 指标输出报告

验收标准：

- 对同一批测试集可重复评测

T28 错误分析表

- 统计 ASR 错误
- 统计术语错误
- 统计抽取遗漏
- 统计生成和校验错误

交付物：

- error analysis 表格

- 高频错误清单

验收标准：

- 能明确指出系统最主要的瓶颈在哪里

T29 展示样例整理

- 准备 3 到 5 条代表性样例
- 一条正常样例
- 一条 ASR 高风险样例
- 一条术语规范化收益明显样例
- 一条审核前后对比样例

交付物：

- 答辩演示样例包

验收标准：

- 可以直接用于汇报和答辩演示

推荐执行顺序

1. T1 到 T3
2. T4 到 T6
3. T7 到 T9
4. T10 到 T13
5. T14 到 T18
6. T22 到 T25
7. T19 到 T21
8. T26 到 T29

注：T5.5（ASR 后处理纠错）应在 T5 完成后、T6 之前执行，可与 T6 合并为一个迭代周期。

这个顺序的核心是先让系统“能跑”，再让系统“更好看”。主诉和现病史润色可以稍晚，因为结构化主干先稳定更重要 [2], [3]。

最小可交付版本

如果时间很紧，至少要完成以下任务：

- T1 到 T6（含 T5.5）
- T7 到 T8
- T10 到 T12
- T14 到 T18
- T22 到 T24
- T26 到 T27

做完这些，就已经有一个完整的一期原型：

- 能上传录音
- 能输出转写
- 能生成结构化病历草稿
- 能查看 evidence
- 能人工修改
- 能做基础评测

后续增强任务

一期完成后，可按优先级继续加：

- 外接 pyannote 或对齐增强 [13], [14]
- 训练轻量 evidence 分类器 [5]
- 引入更强的抽取模型，如 CMUI 或 SAFE [4], [9]
- 加入受限解码术语纠错 [15]
- 加入 checklist 式人工评测 [16]
- 尝试 LoRA 微调开源大模型做结构化直出 [17]

最终建议

开发中最重要的不是把每一层都做复杂，而是始终保证三件事：

- 中间结果可见

- 字段能回链 evidence
- 错误能被人工拦住

只要这三件事守住，这个项目就不仅能做出演示，也能形成一条清楚、可讲、可扩展的本科毕业设计主线。

References

- [1] G. P. Finley *et al.*, “An automated medical scribe for documenting clinical encounters,” *North American Chapter of the Association for Computational Linguistics*, pp. 11–15, Jun. 2018, doi: 10.18653/v1/N18-5003 (<https://doi.org/10.18653/v1/N18-5003>).
- [2] K. Krishna, S. Khosla, J. P. Bigham, and Z. C. Lipton, “Generating SOAP Notes from Doctor-Patient Conversations Using Modular Summarization Techniques,” *Annual Meeting of the Association for Computational Linguistics*, pp. 4958–4972, May 2020, doi: 10.18653/v1/2021.acl-long.384 (<https://doi.org/10.18653/v1/2021.acl-long.384>).
- [3] Y. Zhang *et al.*, “MIE: A Medical Information Extractor towards Medical Dialogues,” *Annual Meeting of the Association for Computational Linguistics*, pp. 6460–6469, Jul. 2020, doi: 10.18653/v1/2020.acl-main.576 (<https://doi.org/10.18653/v1/2020.acl-main.576>).
- [4] Y. Xia *et al.*, “A Speaker-Aware Co-Attention Framework for Medical Dialogue Information Extraction,” *Conference on Empirical Methods in Natural Language Processing*, pp. 4777–4786, 2022, doi: 10.18653/v1/2022.emnlp-main.315 (<https://doi.org/10.18653/v1/2022.emnlp-main.315>).
- [5] K. Krishna, A. Pavel, B. Schloss, J. P. Bigham, and Z. C. Lipton, “Extracting Structured Data from Physician-Patient Conversations By Predicting Noteworthy Utterances,” *ArXiv*, vol. abs/2007.07151, Jul. 2020, doi: 10.1007/978-3-030-53352-6_14 (https://doi.org/10.1007/978-3-030-53352-6_14).
- [6] Q. Wang *et al.*, “A study of entity-linking methods for normalizing Chinese diagnosis and procedure terms to ICD codes,” *Journal of biomedical informatics*, pp. 103418, Apr. 2020, doi: 10.1016/j.jbi.2020.103418 (<https://doi.org/10.1016/j.jbi.2020.103418>).
- [7] V. J. Wei, W. Wang, D. Jiang, Y. Song, and L. Wang, “ASR-EC Benchmark: Evaluating Large Language Models on Chinese ASR Error Correction,” *Conference on Empirical Methods in Natural Language Processing*, pp. 1567–1575, Dec. 2024, doi: 10.48550/arXiv.2412.03075 (<https://doi.org/10.48550/arXiv.2412.03075>).
- [8] G. Hu, S. Lyu, X. Wu, J. Li, and H. Chen, “Contextual-Aware Information Extractor with Adaptive Objective for Chinese Medical Dialogues,” *Transactions on Asian and Low-Resource Language Information Processing*, vol. 21, pp. 1–21, Feb. 2022, doi: 10.1145/3511602 (<https://doi.org/10.1145/3511602>).
- [9] J. Dai, C. Jiang, R. Peng, D. Zeng, and Y. Li, “Chinese medical dialogue information extraction via contrastive multi-utterance inference,” *Briefings in bioinformatics*, Jul. 2022, doi: 10.1093/bib/bbac284 (<https://doi.org/10.1093/bib/bbac284>).
- [10] F. Moramarco *et al.*, “Human Evaluation and Correlation with Automatic Metrics in Consultation Note Generation,” *Annual Meeting of the Association for Computational Linguistics*, pp. 5739–5754, Apr. 2022, doi: 10.48550/arXiv.2204.00447 (<https://doi.org/10.48550/arXiv.2204.00447>).

- [11] A. B. Abacha, W. Yim, G. Michalopoulos, and T. Lin, “An Investigation of Evaluation Metrics for Automated Medical Note Generation,” *ArXiv*, vol. abs/2305.17364, May 2023, doi: 10.48550/arXiv.2305.17364 (<https://doi.org/10.48550/arXiv.2305.17364>).
- [12] A. B. Abacha *et al.*, “MEDEC: A Benchmark for Medical Error Detection and Correction in Clinical Notes,” *ArXiv*, vol. abs/2412.19260, Dec. 2024, doi: 10.48550/arXiv.2412.19260 (<https://doi.org/10.48550/arXiv.2412.19260>).
- [13] H. Bredin, “Pyannote.audio 2.1 Speaker Diarization Pipeline: Principle, Benchmark, and Recipe,” *Interspeech*, pp. 1983–1987, Aug. 2023, doi: 10.21437/interspeech.2023-105 (<https://doi.org/10.21437/interspeech.2023-105>).
- [14] M. Bain, J. Huh, T. Han, and A. Zisserman, “WhisperX: Time-Accurate Speech Transcription of Long-Form Audio,” *Interspeech*, pp. 4489–4493, Mar. 2023, doi: 10.48550/arXiv.2303.00747 (<https://doi.org/10.48550/arXiv.2303.00747>).
- [15] R.-Z. Li and W. Peng, “Dictionary-driven Chinese ASR Entity Correction with Controllable Decoding,” *2023 Asia Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC)*, pp. 1542–1548, Oct. 2023, doi: 10.1109/APSIPAASC58517.2023.10317469 (<https://doi.org/10.1109/APSIPAASC58517.2023.10317469>).
- [16] A. Savkov, F. Moramarco, A. P. Korfiatis, M. Perera, A. Belz, and E. Reiter, “Consultation Checklists: Standardising the Human Evaluation of Medical Note Generation,” *Conference on Empirical Methods in Natural Language Processing*, pp. 111–120, Nov. 2022, doi: 10.48550/arXiv.2211.09455 (<https://doi.org/10.48550/arXiv.2211.09455>).
- [17] S. Zhao *et al.*, “EMRModel: A Large Language Model for Extracting Medical Consultation Dialogues into Structured Medical Records,” *ArXiv*, vol. abs/2504.16448, Apr. 2025, doi: 10.48550/arXiv.2504.16448 (<https://doi.org/10.48550/arXiv.2504.16448>).